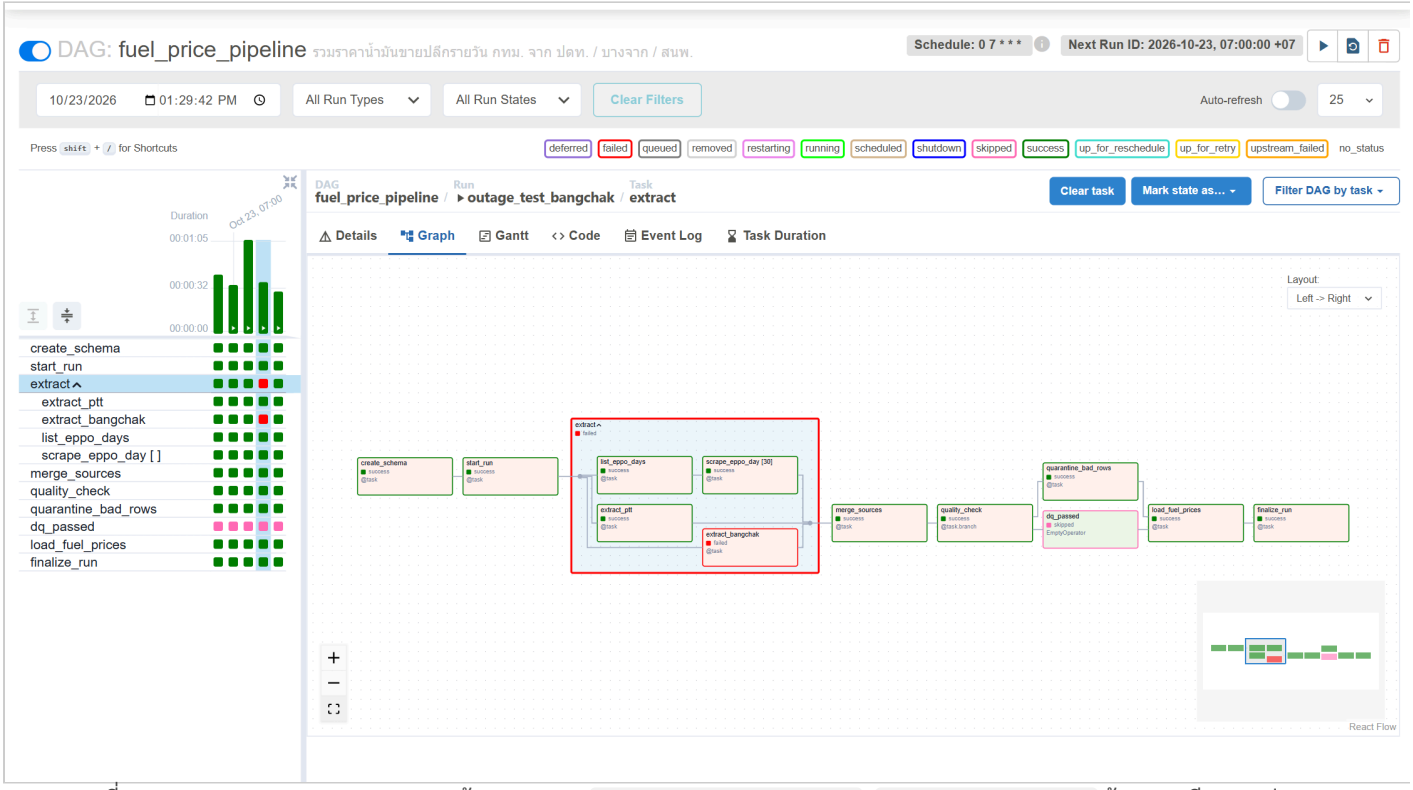
สรุปภาพรวม: ระบบรวมราคาน้ำมันขายปลีกรายวัน กรุงเทพฯ จาก 3 แหล่ง

รายวิชา 02739452 แพลตฟอร์มข้อมูลขนาดใหญ่และการวิเคราะห์ · ข้อสอบปลายภาค ภาคต้น 2569
ชื่อ _____ **รหัสนิสิต** 6621653808 **หมู่** ___ **ลำดับที่** 17
GitHub repo: https://github.com/preeyanann/02739452-17-6621653808

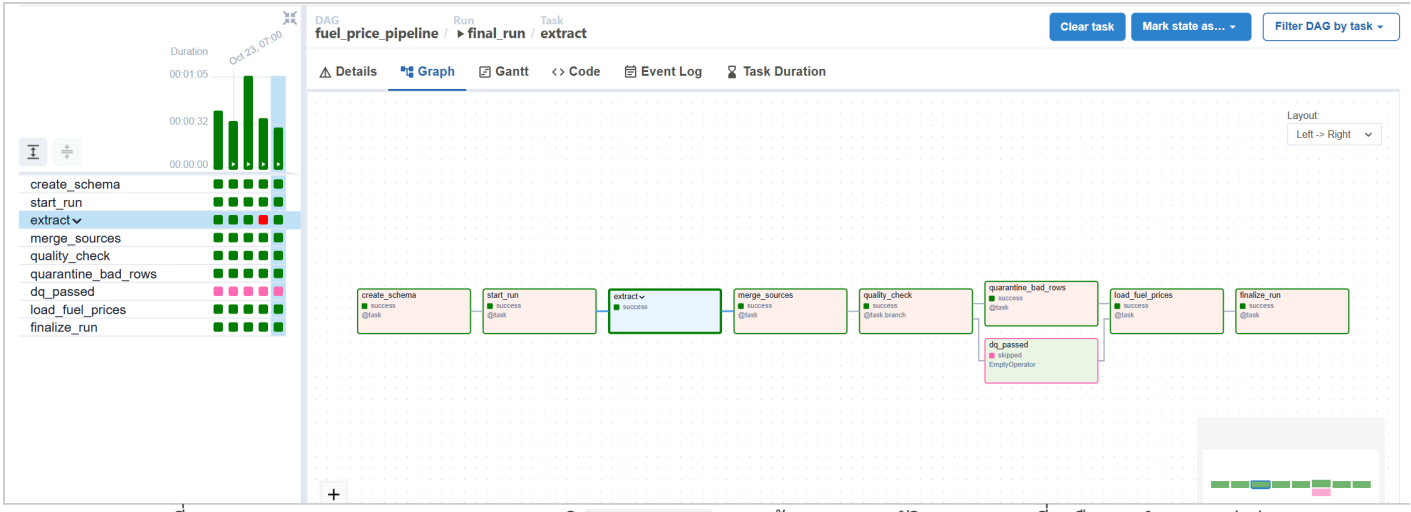
1. ภาพรวมงานแต่ละส่วน — ทำได้ถึงระดับ 3 + โบนัสทั้ง 2 ข้อ

ระดับ	สิ่งที่ทำ	ผล
ระดับ 1	DAG `fuel_price_pipeline`: extract → transform (merge) → load ลง PostgreSQL (`fueldb`) และเว็บ Flask แสดงตารางกับกราฟ	**ครบ**
ระดับ 2	ดึง 3 แหล่งขนานกันใน TaskGroup `extract`, แปลงชื่อน้ำมันทุกแหล่งให้เป็น schema เดียว `(price_date, brand, fuel_code, price)`, ใช้ UPSERT `ON CONFLICT DO UPDATE` (รันซ้ำ 5 รอบ จำนวนแถวคงที่ 1,830), เว็บมี KPI 5 ตัว และตัวกรองชนิดน้ำมัน ผู้ค้า และช่วงวันที่	**ครบ**
ระดับ 3	• **แหล่งล่ม:** `merge_sources` ใช้ `trigger_rule=all_done` และรวมเฉพาะแหล่งที่สำเร็จ ทดสอบด้วย Variable `simulate_down=bangchak_api` ได้ผลรอบนั้นเป็น *partial* และยังโหลดได้ครบ 1,830 แถว • **ตัดซ้ำข้ามแหล่ง:** ราคา PTT มีทั้งจาก ปตท. และ สนพ. ส่วน BCP มีทั้งจากบางจากและ สนพ. จึงเลือก 1 แถวต่อ (วัน, ผู้ค้า, น้ำมัน) โดยให้แหล่งของเจ้าของแบรนด์ชนะ (2,206 แถวดิบ → 1,920 แถว) • **Data Quality + branch:** ตรวจช่วงราคา 10–100 บาท, วันที่ในอนาคต และราคาที่ต่างจากมัธยฐานของผู้ค้าอื่นเกิน 15% ถ้าไม่ผ่าน DAG จะแตกไปทาง `quarantine_bad_rows` แล้วย้ายแถวไปตาราง `dq_rejects` (พบราคา ESSO ผิดปกติ 90 แถว)	**ครบ**
โบนัส	Dynamic Task Mapping: `scrape_eppo_day.expand()` สร้าง task ละ 1 วัน รวม 30 task · หน้าสถานะ pipeline บนเว็บที่ `/status`	**ครบ**

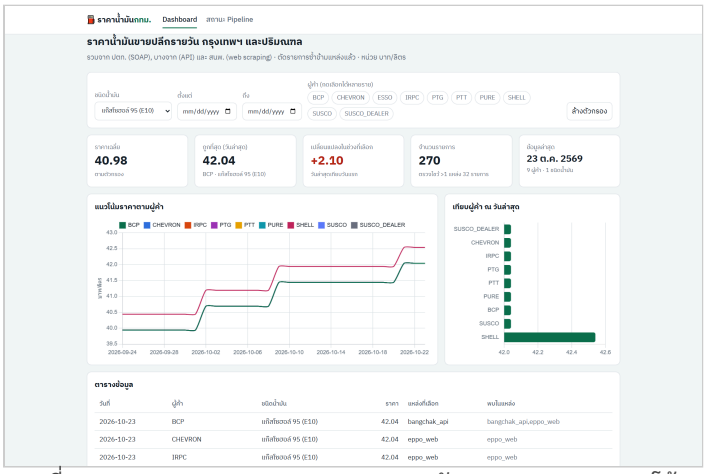
แหล่งข้อมูล: (1) ปตท. SOAP Web Service `GetOilPrice` (2) บางจาก Oil Price API แบบ JSON (3) สนพ. ใช้ **web scraping** ด้วย requests + BeautifulSoup โดย GET หน้า ASP.NET เพื่ออ่าน `__VIEWSTATE` แล้ว POST วันที่ ได้ราคาของ 10 ผู้ค้า (ไม่ใช้ Selenium) ปฏิบัติตาม robots.txt, เว้นระยะ request และไม่เก็บข้อมูลส่วนบุคคล ชุดข้อมูลรวมมี 1,830 รายการ ครอบคลุม 30 วัน, 10 ผู้ค้า และ 11 ชนิดน้ำมัน



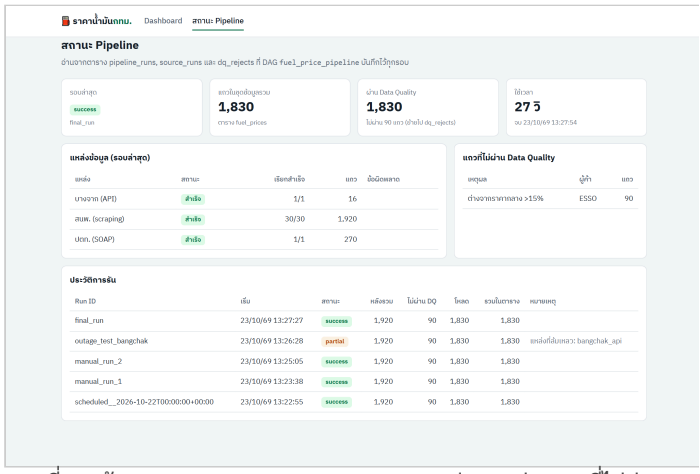
ภาพที่ 1 Graph view (ขวา) และ Grid view (ซ้าย) ของรอบ `outage_test_bangchak`: `extract_bangchak` ล้มเหลว (สีแดง) แต่ merge, quality_check และ load ยังทำงานต่อได้ · `scrape_eppo_day [30]` คือ Dynamic Task Mapping · DQ ไม่ผ่านจึงไปทาง quarantine_bad_rows และ dq_passed ถูก skip



ภาพที่ 2 Graph view และ Grid view ของรอบปกติ `final_run` : Grid ซ้ายแสดงประวัติ 5 รอบ (รอบที่ 4 คือรอบจำลองแหล่งล่ม)



ภาพที่ 3 Dashboard (http://localhost:8000): ตัวกรอง, KPI, กราฟแนวโน้ม, กราฟเทียบผู้ค้า และตาราง (มีแบ่งหน้า)



ภาพที่ 4 หน้าสถานะ Pipeline (/status): สถานะแต่ละแหล่ง, แถวที่ไม่ผ่าน DQ และประวัติการรัน

2. ปัญหาที่พบและวิธีแก้

ปัญหา / อาการ	วิธีหาสาเหตุ	วิธีแก้
1. ตารางราคาบนเว็บ สนพ. มีแต่ 30.00 ทุกช่อง	อ่าน HTML ที่ดึงมาด้วย requests พบว่าเป็นค่า placeholder และราคาจริงถูกเติมด้วย JavaScript ภายหลัง ซึ่งใช้ Selenium ไม่ได้ จึงหา iframe ในหน้าเดียวกันจนพบหน้ารายงาน ASP.NET `ropbydaypublic.aspx`	scrape ฟอร์มแทน: GET หน้าเพื่ออ่าน hidden field (`__VIEWSTATE` , `__EVENTVALIDATION`) แล้ว POST `TbxToDate` ได้รายงานรายวันที่ย้อนหลังได้ และมีครบทุกผู้ค้า
2. scrape สนพ. ล้มเหลวเป็นบางครั้ง ด้วย `ChunkedEncodingError: IncompleteRead`	ดู traceback ใน log ของ task พบว่าเซิร์ฟเวอร์ตัดการเชื่อมต่อระหว่างส่งหน้า 250 KB ซึ่ง urllib3 Retry ไม่ครอบคลุมกรณีที่ตัดกลาง body	เขียน `_with_retry()` ลองใหม่ 3 ครั้งแบบ backoff และแบ่ง scraping เป็น task ละวัน (Dynamic Task Mapping, ขนานไม่เกิน 4) วันที่ล้มเหลวจึงไม่ทำให้วันอื่นล้มตาม
3. ราคาบางจากวันที่ 22 ต.ค. ไม่ตรงกับ สนพ. (41.44 กับ 42.04) ทำให้กราฟมีจุดตก	เทียบแถวที่ซ้ำกันข้ามแหล่งใน `stg_fuel_prices` แล้วอ่าน JSON ของบางจากอีกครั้ง พบว่า `PriceYesterday` คือราคาก่อนการปรับครั้งล่าสุด (วันประกาศ `OilPriceDate`) ไม่ใช่ราคาของ "วันนี้ – 1"	ใช้ `PriceYesterday` กับวันที่ `OilPriceDate` ลบแถวผิดใน staging แล้วรันใหม่ ผลคือราคาตรงกันทุกวัน การเก็บคอลัมน์ `sources` ไว้ช่วยให้ตรวจไขว้แบบนี้ได้
4. DAG import error: `Context key parameter run_id can't have a default`	รัน `airflow dags list-import-errors`	เปลี่ยน default ของ `run_id` จาก `"{{ run_id }}"` เป็น `None` ให้ TaskFlow inject ค่าจาก context เอง

ข้อสังเกตจาก DQ: ราคา ESSO ใน สนพ. ต่ำกว่าผู้ค้าอื่นประมาณ 20% และวันที่มีผล (24 ก.ย. 2568) ไม่ได้อัปเดต กฎ outlier จึงกักแถวเหล่านี้ไว้ ไม่ให้เข้าชุดข้อมูลหลัก

3. การวางแผนและจัดลำดับงาน (13:00–16:00)

เวลา	งาน
13:00–13:15	อ่านโจทย์ เลือกหัวข้อที่มีแหล่งข้อมูลราคาเดียวกันหลายแหล่ง ทดสอบว่าแต่ละแหล่งเรียกได้จริงและอ่าน robots.txt แล้วจึงจองหัวข้อ
13:15–13:25	สำรวจโครงสร้างข้อมูลแต่ละแหล่ง (SOAP, JSON, ฟอร์ม ASP.NET) ออกแบบ schema กลางและกฎแปลงชื่อน้ำมัน
13:25–14:10	เขียน DAG ให้ระดับ 1 ใช้งานได้ก่อน แล้วเพิ่ม TaskGroup, UPSERT, การรับมือแหล่งล่ม, การตัดซ้ำ, DQ branch และ Dynamic Task Mapping ตามลำดับ
14:10–14:40	เขียนเว็บ dashboard และหน้า status ทดสอบรันซ้ำ จำลองแหล่งล่ม และแก้ปัญหาข้อ 2–4
14:40–15:30	ถ่ายภาพหน้าจอ เขียน README และ PDF จากนั้นทดสอบ `docker compose up` จาก repo ใหม่ทั้งหมด
15:30–16:00	เวลาสำรอง: push ขึ้น GitHub ตรวจว่า repo เป็น public และส่งงาน

สิ่งที่ตัดออกและเหตุผล

- **ไม่ทำโมเดลพยากรณ์ราคาหรือ alert ทาง LINE/อีเมล:** โจทย์ไม่ได้ให้คะแนนส่วนนี้ และต้องใช้ API key ซึ่งห้าม commit
- **ดึงย้อนหลังแค่ 30 วัน (ตั้งค่าได้ที่ `FUEL_LOOKBACK_DAYS`):** ข้อมูลเกิน 100 รายการอยู่แล้ว ทั้งยังไม่สร้างภาระให้เว็บหน่วยงาน และอาจารย์รันตรวจได้ในเวลาประมาณ 1 นาที
- **ใช้ LocalExecutor แทน Celery และใช้ Flask + Chart.js แทน framework ใหญ่:** ใช้เวลา build และรันน้อยกว่า และลดโอกาสที่อาจารย์จะรันไม่ขึ้น
- **ไม่ทำหน่วยงานแยกรายจังหวัด:** ขอบเขตที่จองไว้คือกรุงเทพฯ และปริมณฑล ตามที่ทั้ง 3 แหล่งรายงาน